

TP4 : Le partitionnement (Sharding) sous MongoDB


1. Objectif du TP

L'objectif de ce TP est de mettre en œuvre une **architecture MongoDB shardée**, afin de comprendre le fonctionnement du **partitionnement des données**, la répartition de la charge, ainsi que le rôle des différents composants d'un cluster MongoDB shardé.

Le TP met en évidence :

- La scalabilité horizontale de MongoDB
- La gestion des volumes importants de données
- L'équilibrage automatique des données entre plusieurs serveurs

2. Architecture globale du cluster shardé



Un cluster MongoDB shardé repose sur **trois composants essentiels** :

2.1 Composants de l'architecture

1. Config Servers (CSRS – Config Server Replica Set)

- Stockent les métadonnées du sharding
- Indispensables au fonctionnement du cluster
- Répliqués pour assurer la tolérance aux pannes

2. Shards

- Contiennent les données réelles
- Chaque shard est un **replica set**
- Les données sont réparties en **chunks**

3. Mongos (Router)

- Point d'entrée des clients
 - Route les requêtes vers les shards appropriés
 - Interroge les config servers pour localiser les données
-

3. Mise en place du cluster MongoDB shardé

3.1 Ouverture des terminaux

Ouvrir **six terminaux** et leur attribuer des noms explicites, par exemple :

- ConfigSrv
- Router
- Shard1
- Shard2
- Client
- InitReplica

3.2 Création des répertoires de stockage

```
mkdir configsvrdb  
mkdir serv1  
mkdir serv2
```

3.3 Démarrage du Config Server

```
mongod --configsvr --replSet replicaconfig --dbpath configsvrdb  
--port 27019
```

Initialisation du replica set :

```
rs.initiate()
```

3.4 Démarrage du routeur mongos

```
mongos --configdb replicaconfig/localhost:27019 --port 27017
```

3.5 Démarrage des shards

Shard 1 :

```
mongod --replSet replicashard1 --dbpath serv1 --shardsvr --port  
20004
```

Shard 2 :

```
mongod --replSet replicashard2 --dbpath serv2 --shardsvr --port  
20005
```

Initialisation des replica sets :

```
rs.initiate()
```

3.6 Ajout des shards au cluster

Connexion au routeur mongos :

```
mongo --port 27017
```

Ajout des shards :

```
sh.addShard("replicashard1/localhost:20004")
sh.addShard("replicashard2/localhost:20005")
```

4. Activation du sharding

4.1 Activation sur la base de données

```
sh.enableSharding("mabasefilms")
```

4.2 Sharding de la collection

```
sh.shardCollection("mabasefilms.films", { "titre": 1 })
```

- **titre** est la **clé de sharding**
 - Sharding de type **ranged**
-

5. Questions théoriques – Réponses

1. Qu'est-ce que le sharding dans MongoDB et pourquoi est-il utilisé ?

Le sharding est une technique de **partitionnement horizontal** des données permettant de répartir les documents sur plusieurs serveurs afin d'améliorer la **scalabilité** et les **performances**.

2. Différence entre sharding et réPLICATION

- **RéPLICATION** : tolérance aux pannes, haute disponibilité

- **Sharding** : montée en charge et distribution des données
-

3. Composants d'une architecture shardée

- **Mongos**
 - **Config Servers**
 - **Shards**
-

4. Rôle des config servers

Ils stockent :

- Les métadonnées de sharding
 - La localisation des chunks
 - La configuration du cluster
-

5. Rôle du mongos

Il agit comme **routeur intelligent**, redirigeant les requêtes vers les shards concernés.

6. Comment MongoDB choisit le shard d'un document ?

À partir de la **clé de sharding**, MongoDB détermine le chunk cible et donc le shard correspondant.

7. Qu'est-ce qu'une clé de sharding ?

Un champ utilisé pour distribuer les documents dans le cluster.

8. Critères d'une bonne clé de sharding

- Forte cardinalité
 - Distribution uniforme
 - Présente dans les requêtes fréquentes
 - Non monotone
-

9. Qu'est-ce qu'un chunk ?

Un chunk est une **plage de valeurs de la clé de sharding** stockée sur un shard.

10. Fonctionnement du splitting

Lorsqu'un chunk dépasse une taille limite, il est automatiquement **divisé en deux**.

11. Rôle du balancer

Il assure une **répartition équilibrée des chunks** entre les shards.

12. Déplacement des chunks

Le balancer déplace les chunks automatiquement lorsque le cluster est déséquilibré.

13. Hot shard

Shard recevant trop de requêtes.

Solution : bonne clé de sharding ou clé hashée.

14. Problèmes d'une clé monotone

- Concentration des écritures sur un seul shard
- Déséquilibre de charge

15. Activation du sharding

```
sh.enableSharding("db")
sh.shardCollection("db.collection", { champ: 1 })
```

16. Ajout d'un shard

```
sh.addShard("replica/host:port")
```

17. Vérification de l'état du cluster

```
sh.status()
db.stats()
```

18. Quand utiliser une clé hashée ?

- Écritures intensives
 - Répartition uniforme requise
-

19. Quand utiliser une clé ranged ?

- Requêtes par intervalle
 - Analyses chronologiques
-

20. Zone sharding

Permet d'associer des plages de données à des shards spécifiques (ex : par région).

21. Requêtes multi-shards

MongoDB interroge plusieurs shards et agrège les résultats.

22. Optimisation des performances

- Bon choix de clé
 - Indexation adaptée
 - Limiter les requêtes multi-shards
-

23. Indisponibilité d'un shard

Si répliqué : bascule automatique
Sinon : données temporairement indisponibles

24. Migration vers une collection shardée

- Activer le sharding
 - Choisir une clé
 - MongoDB redistribue les données automatiquement
-

25. Outils de diagnostic

- sh.status()
 - Logs MongoDB
 - MongoDB Compass
 - Métriques serveur (CPU, RAM, I/O)
-

6. Conclusion

Ce TP met en évidence l'importance du **sharding** pour la gestion de grandes volumétries de données. MongoDB offre une solution robuste et automatisée pour la montée en charge horizontale, à condition de choisir judicieusement la clé de partitionnement.